

Códigos de Markov

Introdução

Processo de Markov

Códigos de Markov de tempo discreto

Matriz de transição

K dependent Markov Chain

Equações de Chapman-Kolmogorov

Classificação de Estados

Distribuição de Probabilidades

Steady State

Códigos de Markov de tempo contínuo

Matriz de taxa

Equações de Chapman-Kolmogorov

Distribuição transiente

Steady State

Equações de Balance

Soluções Numéricas para códigos de Markov

Método Direto: Gaussian Elimination

Método Iterativo:

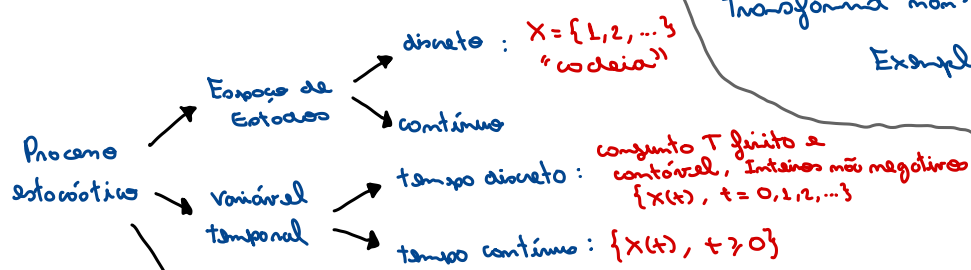
Power method

Introdução

- * Um processo estocástico é definido como uma família de variáveis aleatórias $X(t) \in T$
- * t geralmente é o tempo
- * Se T é discreto \rightarrow discrete time stochastic process
- * Se T é contínuo \rightarrow continuous time stochastic process
- * $X(t)$ são os estados

Processo de Markov

Se os estados futuros dependem apenas do estado presente, então é um processo de Markov



Cadeias de Markov de tempo discreto (DTMC)

Definição: $P[X_{n+1} = x_{n+1} | X_n = x_n, \dots, X_0 = x_0] = P[X_{n+1} = x_{n+1} | X_n = x_n]$

Matriz de transição:

Se P é invariante ao tempo, ela é dito homogênea ou seja, as prob. de transição são constantes ou estacionárias. Nesse caso, dizemos que a cadeia de Markov é homogênea.

K-dependent Markov Chain:

transforma non-Markov \rightarrow Markov.

Exemplo:



$S^k \text{ states} = RR, RC, RS, CR, CC, CS, SR, SC, SS$

Notação:

$P(X(t) = i) = P(X_t = i)$

↑ tempo ↑ estado

memória

estacionária

$P(X(t) \leq x) = P(X(t+\alpha) \leq x)$

Markov: (Homogenea)


future não depende do passado. Somente do presente

$P(X_{t+1} = x_{t+1} | X_t = x_t, \dots, X_0 = x_0) = P(X_{t+1} = x_{t+1} | X_t = x_t)$

Chapman-Kolmogorov equation

Como encontrar a probabilidade dois dias depois?

C (Cloud) dois dias depois do dia que hoje é S (Sunny)



$$P_{SR}P_{RC} + P_{SC}P_{CC} + P_{SS}P_{SC} = \sum_{w=\{R,C,S\}} P_{Sw}P_{wc}$$

to

$$P = \begin{bmatrix} * & * & * \\ * & * & * \\ * & * & * \end{bmatrix} \quad \text{from}$$

$$\begin{bmatrix} P_{SR} & P_{SC} & P_{SS} \end{bmatrix} \begin{bmatrix} P_{RC} \\ P_{CC} \\ P_{SC} \end{bmatrix}$$

$$P_{SR}P_{RC} + P_{SC}P_{CC} + P_{SS}P_{SC}$$

Generalização (Prova): P deve ser homogênea!

$$P[X=j | X_0=i] = \sum_{K \in S} P[X=j, X=K | X_0=i]$$

Bayes Rule
 $P(A,B,C) = P(A|B,C)P(B|C)$

$$\sum_{K \in S} P[X=j | X=K, X_0=i] P[X=K | X_0=i]$$

Markov property

$$\sum_{K \in S} P[X=j | X_m=K] P[X_m=K | X_0=i]$$

$$P = P^m P^m$$

$$\begin{cases} P(A|B,C) = \frac{P(A,B,C)}{P(B,C)} \\ P(B|C) = \frac{P(B,C)}{P(C)} \\ P(A,B|C) = \frac{P(A,B,C)}{P(C)} \end{cases}$$

$$P(A,B,C) = \frac{P(A,B|C)P(C)}{P(B|C)P(C)}$$

Classificação de Estados

alcançável: $i \rightarrow j$ começando em i
comunicante: $i \leftrightarrow j$

Se existe um path



transiente

absorvedor:



recorrente:

Se não é transiente



Periódico:



não Periódico

Se o estado não for periódico

$\begin{cases} i \rightarrow k \rightarrow i & t=2 \\ i \rightarrow k \rightarrow j \rightarrow k \rightarrow i & t=4 (2t) \end{cases}$
Se $t > 1$ e múltiplos de t (Ex. $t, 2t, 3t, \dots$)

* Se todos os estados são comunicantes então a cadeia é irredutível


* Estados recorrentes aperiódicos são chamados de ergódicos

Distribuição de Probabilidade

$$\pi_i(m) = P[X_m = i]$$

$$\begin{aligned} P[X_m = i] &= P[X_m = i | X_0 = 1]P[X_0 = 1] + \\ &P[X_m = i | X_0 = 2]P[X_0 = 2] + \\ &\vdots \\ &P[X_m = i | X_0 = K]P[X_0 = K] \\ &= \sum_{K \in S} \underbrace{P[X_m = i | X_0 = K]}_{p^m} \underbrace{P[X_0 = K]}_{\pi_K(0)} \end{aligned}$$

$$\pi(0) p^m = \pi(m)$$



Probabilidade de Estados Estacionários

$\begin{cases} P \text{ é matriz de transição homogênea} \\ z \text{ é o vetor de Prob. de cada estado} \end{cases}$

Se $zP = z$ então z é estacionário

Dado P , a medida que vamos potencializando P (Ex. P^2, P^3, P^5, P^∞), percebemos que as linhas de P ficam iguais

Ou seja, é tudo igual independentemente de onde se começa. π não muda!

$$\pi P = \pi$$

balance Equation

Cadeias de Markov de tempo

Contínuas

i, j e K inteiros e $t \geq 0, s \geq 0$ e $0 \leq u \leq s$ nos tempos:


$$P[X(s+t) = K | X(s) = i, X(u) = j] = P[X(s+t) = K | X(s) = j]$$

Se for uma cadeia homogênea: A prob. depende apenas de z .

$$P_{ij}(z) = P[X(s+z) = j | X(s) = i] = P[X(z) = j | X(0) = i]$$


Sobrevém também que $\sum_{j \in S} p_{ij}(z) = 1$

Matriz de taxa



* Vamos associar $\begin{cases} \text{Prob.} = \text{distância} \\ \text{taxa} = \text{velocidade} \end{cases}$

$$q_{ij}(t) = \lim_{\Delta t \rightarrow 0} \frac{p(t, t+\Delta t)}{\Delta t}$$



Motriz de taxa (Cont.)

$$\begin{cases} p_{ij}(t, t+\Delta t) = q_{ij}(t) \Delta t \\ 1 - p_{ii}(t, t+\Delta t) = \sum_j p_{ij}(t, t+\Delta t) \end{cases}$$

Se fizermos:

$$1 - p_{ii}(t, t+\Delta t) = \sum_j p_{ij}(t, t+\Delta t)$$

$$1 - q_{ii}(t) \Delta t = \sum_j q_{ij}(t) \Delta t$$

$$\lim_{\Delta t \rightarrow 0} \left(\frac{1}{\Delta t} - \frac{q_{ii}(t) \Delta t}{\Delta t} \right) = \lim_{\Delta t \rightarrow 0} \sum_j \frac{q_{ij}(t) \Delta t}{\Delta t}$$

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} - \lim_{\Delta t \rightarrow 0} q_{ii}(t) = \lim_{\Delta t \rightarrow 0} \sum_j q_{ij}(t)$$

$$q_{ii}(t) = - \sum_j q_{ij}(t)$$

ou seja:
$$\begin{cases} q_{ii}(t) + \sum_j q_{ij}(t) = 0 \\ p_{ii}(t, t+\Delta t) + \sum_j p_{ij}(t, t+\Delta t) = 1 \end{cases}$$

$$Q(t) = \lim_{\Delta t \rightarrow 0} \left\{ \frac{P(t, t+\Delta t) - I}{\Delta t} \right\}$$

Equações de Chapman Kolmogorov

Se a cadeia não for homogênea:

$$p_{ij}(\omega, t) = \sum_{\text{all } k} p_{ik}(\omega, u) p_{kj}(\omega, t)$$

Se a cadeia for homogênea:

$$p_{ij}(t+\Delta t) = \sum_{\text{all } k} p_{ik}(t) p_{kj}(\Delta t)$$

Vamos tirar o Δt da equação:

$$p_{ij}(t+\Delta t) = \sum_{\text{all } k} p_{ik}(t) p_{kj}(\Delta t)$$

$$p_{ij}(t+\Delta t) = \sum_{k \neq j} p_{ik}(t) p_{kj}(\Delta t) + p_{ij}(t) p_{jj}(\Delta t)$$

$$\frac{p_{ij}(t+\Delta t) - p_{ij}(t)}{\Delta t} = \sum_{k \neq j} \frac{p_{ik}(t) p_{kj}(\Delta t)}{\Delta t} + \frac{p_{ij}(t) p_{jj}(\Delta t)}{\Delta t} - \frac{p_{ij}(t)}{\Delta t}$$

$$\frac{p_{ij}(t+\Delta t) - p_{ij}(t)}{\Delta t} = \sum_{k \neq j} \frac{p_{ik}(t) p_{kj}(\Delta t)}{\Delta t} + p_{ij}(t) \left(\frac{p_{jj}(\Delta t) - 1}{\Delta t} \right)$$

q_{kj} q_{jj}

$$\frac{d p_{ij}(t)}{dt} = \sum_{\text{all } k} p_{ik}(t) q_{kj}$$

Forma matricial

$$\frac{dP(t)}{dt} = P(t) Q$$

Distribuição transiente

DTMC: $\pi = \pi P$

CTMC: $\frac{d\pi(t)}{dt} = \pi(t) Q$

Estado Estacionário: (steady state)

Sobemos que no estado estacionário, não existe variação em π , ou seja

$\frac{d\pi(t)}{dt} = 0$, ou seja

$\pi(t) Q = 0$

Global Balance Equations

Sobemos que $\sum \pi = 1$, podemos escrever:

$\sum_{i \neq j} \pi_i q_{ij} = 0$

$\sum_{i \neq j} \pi_i q_{ij} + \pi_j q_{jj} = 0$


$\sum_{i \neq j} \pi_i q_{ij} = -\pi_j q_{jj}$

$\sum_{i, i \neq j} \pi_i q_{ij} = \pi_j \sum_{i, i \neq j} q_{ji}$

total flow
in


total flow
out

Example:



$\pi_2 q_{23} + \pi_2 q_{21} = \pi_1 q_{12} + \pi_3 q_{32}$

Soluções Numéricas para Cadeias de Markov



Gaussian Elimination:

Steady State
Homogeneous
CTMC

$\begin{cases} \pi Q = 0 \\ \sum \pi = 1 \\ \pi \geq 0 \end{cases}$

Resolver $Ax = b$
Então: $Q^T \pi^T = 0$
 $A \quad x \quad b$

Power method

para DTMC, temos $\pi = \pi P$, podemos fazer $\pi \leftarrow \text{random odds que } |\pi| = 1$ e

$\pi^{k+1} = \pi^k P$

e loopar até $|\pi^{k+1} - \pi^k| < \epsilon$ definido pelo usuário