

Regressão linear

Introdução

Modelo de regressão linear

Forma matricial

Interpretação para o caso Bidimensional

Definição sobre o erro

Método dos Mínimos Quadrados

Forma Matricial

Média e variância de Y para B

Porque usar Mínimos Quadrados

Bias e Variância tradeoff

Estratégias de Regularização

Introdução

eg. para estimar o valor esperado de y dado x .

a relação entre a resposta (y) e as variáveis de uma regressão

linear

500 equações usando uma abordagem de mínimos quadrados

Estimamos uma regressão linear em IA, em classe modelo

Equação da Regressão Linear

Para estimar o valor de y usando o seguinte modelo para o caso de múltiplas variáveis.

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i$$

Onde y_i é o valor esperado que o modelo irá prever, β são os coeficientes de ajuste, x_i a variável explicativa (variáveis) e ϵ_i o erro associado ao erro da medição. ele engloba todos os fatores residuais da observação.

Nome como, podemos dizer que

$$\hat{y}_i = y_i - \epsilon_i$$

Forma Matricial

$$y = X\beta + \epsilon$$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_{11} & \dots & x_{1p} \\ 1 & x_{21} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \quad \epsilon = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$


$m \times 1$ $m \times p+1$ $p \times 1$ $m \times 1$

Resíduos

Interpretação para o caso Bidimensional

Por simplicidade, vamos considerar o caso bidimensional, onde:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$



Definição sobre o EVD:

$$* E[\epsilon_i] = \bar{\epsilon}_i = 0$$

$$* Var[\epsilon_i] = E[(\epsilon_i - \bar{\epsilon}_i)^2] = \sigma^2$$

$$* E[y_i] = E[(\beta_0 + \beta_1 x_i + \epsilon_i)] = \beta_0 + \beta_1 x_i = \mu_i$$

$$\leadsto E[y] = \beta X$$

$$* Var[y_i] = \sigma^2$$

- * X é fixo, não é uma V.A.
- * θ não os parâmetros, não é uma V.A
- * y é a variável dependente, é V.A
- * ϵ é uma V.A com $E[\epsilon] = 0$ e $Var[\epsilon] = \sigma^2$

* Como assumimos que $\epsilon_i \sim N(0, \sigma^2)$, ϵ_i e ϵ_j $\forall i, j$ $i \neq j$ não são independentes, $cov(\epsilon_i, \epsilon_j) = 0$

Método dos Mínimos Quadrados

* Como estimar $[B_0, B_1, \dots, B_p]^T$?

* Método mais utilizado é o mínimo quadrados (least squares)

* Técnica de otimização matemática que procura encontrar o melhor ajuste (B) para o conjunto de dados que minimiza a soma dos quadrados entre o valor estimado (\hat{y}) e o valor observado (y)

* Erros diferenças são chamados de resíduos

$$L(B) = \sum_{i=1}^n (y_i - E[y_i])^2$$

Vamos analisar o caso bidimensional:

$$L(B) = \sum_{i=1}^n (y_i - E[y_i])^2 = \sum_{i=1}^n (y_i - B_0 - B_1 x_i)^2$$

Para minimizar, basta derivar em relação a B_0 e B_1 :

$$\frac{\partial L}{\partial B_0} = -2 \sum_{i=1}^n (y_i - B_0 - B_1 x_i) = 0$$

$$-2 \left[\sum_{i=1}^n y_i - n B_0 - B_1 \sum_{i=1}^n x_i \right] = 0$$

$$B_0 = \bar{y} - B_1 \bar{x}$$

$$L(B) = \sum_{i=1}^n (y_i - B_0 - B_1 x_i)^2$$

$$\frac{\partial L}{\partial B_1} = -2 \sum_{i=1}^n (y_i - B_0 - B_1 x_i) x_i = 0$$

$$B_0 = \bar{y} - B_1 \bar{x}$$

$$B_1 = \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})}$$

Forma Matricial

$$L(B) = (Y - XB)(Y - XB)^T$$

$$* L(B) = Y^T Y - 2B^T X^T Y + B^T X^T X B$$

$$\frac{\partial L(B)}{\partial B} = 0 - 2X^T Y + 2X^T X B \rightarrow \frac{\partial L(B)}{\partial B} = 0$$

$$B = (X^T X)^{-1} X^T Y$$

* $(X^T X)^{-1}$ é uma matriz singular

Não tem inversão única

* B não é único $\rightarrow \hat{B}$

Variação de B

$$Var[\hat{B}] = Var[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T Var[Y]$$

$$Var[\hat{B}] = (X^T X)^{-1} X^T \sigma^2$$

* Podemos usar um estimador da variância para o σ^2

$$s^2 = \frac{1}{n - (p+1)} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

número de parâmetros B

Porque usar mínimos quadrados?

- * $L(\beta)$ é um estimador BLUE (Best Linear Unbiased Estimator)
- * Um bom estimador deve ser unbiased e low variance
- * bias and variance trade-off

Porque fazemos de Gauss-Markov se:

- * $E[e_i] = 0$
- * $Var[e_i] = \sigma^2$ para todo i , (constante)
- * $Cov(e_i, e_j) = 0$ para todo i, j onde $i \neq j$

Então OLS é o melhor estimador BLUE

$$LS: \hat{\beta} = (X^T X)^{-1} X^T Y = C E[Y] = C E[X\beta + e]$$

$$E[\hat{\beta}] = C [E[X\beta] + E[e]] = (X^T X)^{-1} X^T X \beta = \beta \quad E[\hat{\beta}] = I\beta$$

$$Var[\hat{\beta}] = Var[(X^T X)^{-1} X^T Y] = Var[C Y] = C Var[Y] C^T$$

$$Var[\hat{\beta}] = C C^T \sigma^2 = (X^T X)^{-1} \sigma^2$$

LS tem low Bias mas alto variância

Como reduzir? estratégia para adaptar

a função custo \rightarrow Regularização

\uparrow Bias \downarrow variance

Ridge Regression

$$L(\hat{\beta}) = \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Derivar e igualar a zero

$$\hat{\beta} = (I\lambda + X^T X)^{-1} X^T Y$$

- * melhor quando novos dados
- * adiciona mais bias na estimação de β

Regression Lasso

$$L(\hat{\beta}) = \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

* Segue o tamanho de β